

# 소상공인을 위한 AI 조기 경보 시스템

통계가 체질

박채원, 이지연, 장준한, 조민수

# 목차

*Table of Contents*

❶ 분석 배경

❸ 전처리

❺ 모델링 결과 해석

❷ 위기 상황 정의

❹ 모델링

❻ 활용 및 제언

# 1 분석 배경

# 분석 필요성

## 1. 소상공인

- 지역 내 고용, 소비, 생활 서비스의 기반
- 소상공인 기업체 수 596만1000개, 종사자 수 955만1000명


출처: 중소벤처기업부

## 2. 소상공인·가맹점의 폐업률 증가

"폐업 100만명"... 2025년에는 관련 통계상 처음으로 100만명 돌파"  
"소상공인 40% "3년 못넘기고 폐업"

## 3. 소상공인·가맹점주 데이터 기반 신호 감지 어려움 문제

분석 인프라 및 전문 역량의부족 → 구조적 한계 발생



▲자료=중소기업중앙회

# 분석 필요성

소상 공인 중 요식업에서 폐업률이 뚜렷한 비중을 보이며,  
빅데이터 활용에서도 부진한 양상이다.

이를 해결하기 위해 빅데이터를 활용한 요식업 AI 조기 경보 모델 활용





그림1 업종별 소상공인 디지털 기술활용 비중(%)




※ 출처: 소상공인 디지털 전환 지원방안('20.9.17)



## ② 위기 상황 정의

# 업종별 운영 개월 수 구간

10가지 업종에 대해



## 1. 업종 분류

세부 업종 73가지를 10개로 분류 후 분석을 진행, 운영개월수는 6개 구간으로 나뉘며, 0구간에 가까울수록 상위.

## 2. 장기 영업 업종


한식, 중식, 식료품에서 운영 개월 수 0,1 구간이 30%이상으로 타 업종에 비해 장기 운영 가맹점이 많은 것을 알 수 있음

## 3. 단기 영업 업종

양식, 카페, 분식, 일식에서는 운영 개월 수 구간 4,5 구간이 30~40%로 타 업종에 비해 가맹점의 운영 개월 수가 작은 것을 알 수 있음

# 업종별 고객 성별 및 연령대 비율

10가지 업종별



## 1. 업종 분류

앞서 나눈 분류 기준 그대로 업종별 고객의 성별 및 연령대 비율을 살펴봄

## 2. 중장년층 선호 업종

운영 개월 수가 타 업종에 비해 길었던 한식, 중식, 식료품에서는 고령층 고객 비중이 높음  
한식 및 중식에서는 남성이, 식료품에서는 여성 고령층 고객 비중이 높은 것을 알 수 있음

## 3. 청년층 선호 업종

양식, 카페, 분식, 일식은 비교적 10-20대의 비중이 높았는데, 특히 4개 업종 모두 여성 10-20대의 비중이 높음



# 업종 분류



3가지 업종으로 대분류

| 항목      | 세부내용                                                                      | 비고          |
|---------|---------------------------------------------------------------------------|-------------|
| 장기 안정형  | - 운영개월수 상위(0~1구간) 비중 높음- 매출금액 상위 비중 높음- 재방문율·고령층 고객 비중 높음                 | 한식·중식·식료품   |
| 트렌드 민감형 | - 운영개월수 짧고 상위구간 비중 낮음- 젊은층(20~30대) 비중 높고 재방문율 낮음- 매출건수 변동성 큼<br>(유동고객 중심) | 양식·카페·분식·일식 |
| 중간형     | - 운영개월·매출 모두 중간 수준- 고객층 다양, 재방문율 중간                                       | 베이커리·주점·기타  |


업종에 따른 운영 구간 및 고객 층의 유의미한 차이가 있었고, 차이를 반영해주기 위해 3가지 업종으로 분류 후 분석을 진행함

# 폐업 가맹점

업종 분류에 따른 운영 구간 및 매출금액 구간 분포



## 2 위기 상황 정의



폐업 점포들의 월별 매출 비율(M1\_SME\_RY\_SAA\_RAT)을 폐업 시점을 기준으로 정렬하여 분석한 결과

- 폐업 약 7개월 전부터 완만한 하락세가 시작됨
- 3~4개월 전부터 급격한 매출 감소가 뚜렷하게 나타남

따라서 본 연구에서는 3개월 후 매출 30% 이상 하락을 위기 상황으로 정의하고 분석함

### ③ 전처리

데이터 개요 (Overview)

| Dataset 1 (기본정보)   |                | Dataset 2 (매출정보)       |                       | Dataset 3 (고객정보)                  |                                         |
|--------------------|----------------|------------------------|-----------------------|-----------------------------------|-----------------------------------------|
| 변수명                | 설명             | 변수명                    | 설명                    | 변수명                               | 설명                                      |
| ENCODED_MCT        | 가맹점 고유 식별번호    | TA_YM                  | 기준 연월 (예: 202301)     | M12_MAL_1020_RAT ~ M12_MAL_60_RAT | 남성 고객 비중 (연령대별: 10~20, 30, 40, 50, 60대) |
| MCT_BSE_AR         | 점포의 영업 면적      | MCT_OPE_MS_CN          | 월평균 운영 개월 수           | M12_FME_1020_RAT ~ M12_FME_60_RAT | 여성 고객 비중 (연령대별)                         |
| MCT_NM             | 가맹점 이름         | RC_M1_SAA              | 월평균 매출금액              | MCT_UE_CLN_REU_RAT                | 재방문 고객 비중                               |
| MCT_BRD_NUM        | 브랜드 구분 코드      | RC_M1_TO_UE_CT         | 거래 건수                 | MCT_UE_CLN_NEW_RAT                | 신규 고객 비중                                |
| MCT_SIGUNGU_NM     | 시군구 명칭 (행정구역)  | RC_M1_UE_CUS_CN        | 이용 고객 수               | RC_M1_SHC_RSD_UE_CLN_RAT          | 거주 지역 고객 비율                             |
| HPSN_MCT_ZCD_NM    | 우편번호 지역명       | RC_M1_AV_NP_AT         | 객단가 (평균 결제 금액)        | RC_M1_SHC_WP_UE_CLN_RAT           | 직장 지역 고객 비율                             |
| HPSN_MCT_BZN_CD_NM | 상권 코드명         | APV_CE_RAT             | 취소율 구간                | RC_M1_SHC_FLP_UE_CLN_RAT          | 유동 인구 고객 비율                             |
| ARE_D              | 개업일 (YYYYMMDD) | DLV_SAA_RAT            | 배달 매출 비율              |                                   |                                         |
| MCT_ME_D           | 폐업일 (YYYYMMDD) | M1_SME_RY_SAA_RAT      | 매출 추세율(최근 1개월)        |                                   |                                         |
|                    |                | M1_SME_RY_CNT_RAT      | 거래건수 추세율(최근 1개월)      |                                   |                                         |
|                    |                | M12_SME_RY_SAA_PCE_RT  | 매출 성장률(최근 12개월)       |                                   |                                         |
|                    |                | M12_SME_BZN_SAA_PCE_RT | 상권 대비 매출 성장률(최근 12개월) |                                   |                                         |
|                    |                | M12_SME_RY_ME_MCT_RAT  | 동일 업종 내 평균 대비 매출 비율   |                                   |                                         |
|                    |                | M12_SME_BZN_ME_MCT_RAT | 상권 내 평균 대비 매출 비율      |                                   |                                         |




## 결측치 및 이상값 처리

### 결측치 처리

- 컬럼별 결측치 개수와 비율 계산
- 결측치가 많은 순서대로 정렬: 폐업일, 브랜드 구분코드, 업종, 취소율 구간

### 이상치 처리

- 모델 학습 시 음수 이상치 (-999999) 제거
- 데이터 없음을 명시적 0으로 처리해 변수 간 일관성 확보



|                    | Missing Values | Percent   |
|--------------------|----------------|-----------|
| MCT_ME_D           | 84256          | 97.304539 |
| MCT_BRD_NUM        | 74865          | 86.459175 |
| HPSN_MCT_BZN_CD_NM | 21419          | 24.736113 |
| APV_CE_RAT         | 6632           | 7.659083  |

### 3 전처리

#### 날짜 정규화 및 논리 검증 (Date Cleaning & Logical Check)

##### 날짜 정규화

- 날짜 데이터(open\_date, close\_date, snapshot\_date)를 문자열에서 datetime 형식으로 변환
- 기준월(snapshot\_date)은 각 월의 말일로 맞추어 월별 데이터를 시간 순서로 정렬

##### 논리 검증

- 변환 후, 논리적 오류(폐업일 < 개업일) 를 검증하여 이상 레코드 제거


Before

'20230105'  
'20230131'



After

2023-01-05  
2023-01-31



### 3 전처리

#### 범주형 변수값 점검 및 통일

##### 범주형 변수값 점검

- 데이터셋 내 주요 구간형 변수의 실제 고유값 확인
- 범주명 혼합, 결측 및 비정상 문자열이 포함된 변수 점검

##### 범주형 변수값 통일

- (하위 10% 이하), 6\_90%초과(하위 10% 이하)와 같은 불일치 표기를 표준화된 값으로 일괄 통일

##### 범주형 변수값 OHE

- 범주형 변수 피쳐 반영을 위해 ohe-hot encoding 진행



## 4 모델링

# Target 정의: 위기의 기준

## 위기 판단 기준

3개월 후 매출이 30% 이상 급락하는 경우를  
"위기" 상황으로 정의

**target = 1**  
3개월 뒤 위기 발생

**target = 0**  
3개월 뒤 정상 유지

**target = NaN**  
미래 데이터 부재 (학습 제외)

## 계산 프로세스

01

---

데이터 정렬  
가맹점별 시간순 정렬

02

---

매출 비교  
3개월 후의 매출 준비

03

---

변화율 계산  
 $(\text{미래 매출} - \text{현재 매출}) / \text{현재 매출}$

04

---

임계값 계산  
-0.3 이하면 위기(1), 아니면 정상(0)

# 시계열 데이터 분할 전략

- 모델은 과거의 데이터로 미래를 예측해야 함
- 무작위 분할 시 미래 데이터가 학습에 포함되어 데이터 누수(leakage)가 발생하므로, 시간 흐름을 기준으로 3등분



Train Data  
~2024-05-31  
58,331건  
패턴 학습용 과거 데이터



Validation Data  
2024-06-01 ~ 2024-08-31  
11,776건  
과적합 방지 모의고사



Test Data  
2024-09-01 ~ 2024-12-31  
4,026건  
최종 성능 평가

## Validation의 역할과 AUC 지표

Train 데이터로 한 세트 학습 완료 시마다 Validation 데이터로 성능을 평가

AUC  
1.0에 가까울수록: 모델이 '위기(1)'와 '정상(0)'을 완벽하게 구별해낸다는 뜻  
0.5에 가까울수록: 모델이 '찍기'와 다름없는, 쓸모없는 모델이라는 뜻

조기 종료 조건  
AUC가 100번 연속으로 향상되지 않으면 과적합으로 판단하여 학습 중단

최적 모델 선택  
Validation 점수가 가장 높았던 시점의 모델을 최종 결과로 채택

# Feature의 정의 및 선택

463개

모델 예측에 사용될 입력 변수의 총 개수

Target 제외

타겟 변수와 타겟 계산에 사용된 변수는 피처에서 제외

그룹핑 변수 제외

업종그룹 분류 변수는 경로(guard) 역할만 수행하므로 피처 목록에서 제외

순수 입력 변수만

미래 정보 누수 없이 과거 데이터만으로 구성된 순수 입력 변수 사용

# Risk Score Guard Model 구축

업종 그룹별 특화 모델 시스템

## 모델 구조

하나의 통합 모델이 아닌, 3개의 LightGBM 전용 모델을 업종 그룹별로 구축하여 각 그룹의 특성에 최적화된 예측을 수행



장기 안정형



트렌드 민감형



중간형

## 핵심 기술

01

### 불균형 처리

정상 대비 위기 비율 계산, 소수 클래스 가중치 부여

02

### 조기 종료

Validation AUC 100회 미개선 시 자동 중단

03

### 최적 임계값

F1-Score 최대화하는 Best Threshold 탐색

04

### 평가 지표

ROC AUC (전반적 성능)와

Average Precision/PR AUC (불균형 데이터 핵심 지표)를 동시 활용



# 핵심 전략: 업종 그룹 분류 체계

1차 매핑  
카테고리 맵으로 12개 업종 대분류로 통합

- 한식
- 중식
- 식료품/유통
- 일식
- 양식/세계요리
- 분식/패스트푸드
- 카페/디저트
- 베이커리/떡
- 주점/유흥
- 기타
- 기타/미분류

2차 매핑  
그룹 맵으로 3개 업종그룹으로 최종 분류

장기 안정형

- 한식
- 중식
- 식료품/유통

경기 둔감, 수요 꾸준

중간형

- 베이커리/떡
- 주점/유흥
- 기타 업종

중간 성격 및 분류 외

트렌드 민감형


- 일식
- 양식/세계요리
- 카페/디저트
- 분식/패스트푸드

유행에 따른 높은 변동성

경로 지정  
각 그룹별 전용 모델에 예측 위임

Target

# The 'Guard' Logic: 실행 로직




최종 결과: models\_by\_group 딕셔너리에 3개의 특화된 LightGBM 모델이 저장되어, 신규 가맹점 예측 시 해당 업종그룹 모델을 선택하여 사용

## ⑤ 모델링 결과 해석



# 업종 그룹별 예측 성능

ROC AUC Scores



주요 인사이트

- 장기 안정형이 가장 높은 예측 정확도 (0.87)를 기록
- 트렌드 민감형은 변동성이 크지만 0.82의 양호한 성능을 보임
- 모든 그룹이 0.79 이상의 AUC를 달성하여 실용적 활용이 가능함을 확인
- 그룹별 특화 모델 전략이 효과적임을 검증하였음

각 모델은 F1-Score를 최대화하는 최적 임계값을 통해 '위기' 여부를 판단하며, PR AUC 지표로 불균형 데이터 성능을 추가 검증

## ⑥ 활용 및 제언

# 활용 및 제언

## 빨간불 - 위험

의미: 3개월 뒤 매출 급락 가능성이 매우 높은 고위험군

대응: 즉각 개입 필요

- 1:1 집중 컨설팅
- 프로모션 지원
- 긴급 현장 방문

## 노란불 - 주의

의미: 위험 징후가 포착된 관찰 필요 그룹

대응: 예방 관리

- 정기 모니터링
- 자가 진단 가이드 제공
- 개선 방안 제시

## 초록불 - 안전

의미: 안정적으로 운영 중인 저위험군

대응: 표준 관리

- 현행 유지
- 업계 정보 제공
- 우수 사례 공유

업종 그룹별 리스크스코어가드모델 활용: 단일 가맹점 리스크 스코어 예측 예시

선택된 예시 가맹점 ID: 000F03E44A  
가맹점의 업종 그룹: 장기 안정형  
예측 기준 시점: 2024-09

특정 가맹점의 향후 3개월 내 매출 급락 위험을 예측한 결과

[예측 결과]

> 3개월 뒤 (lag=3) 매출 급락(위기) 확률: 5.84 %

(참고: 이 가맹점의 3개월 뒤 실제 위기 여부: 0)

# 기대 효과 및 실무 적용 가치

## 조기 위험 감지

매출 급락 3개월 전 사전 경보로 선제적 대응 체계 구축

## 정밀한 자원 배분

고위험 가맹점에 본사 역량 집중, 저위험 가맹점은 효율적 관리

## 실시간 모니터링

신호등 시스템으로 전체 가맹점 현황을 한눈에 파악 가능

## 실시간 모니터링

신호등 시스템으로 전체 가맹점 현황을 한눈에 파악 가능

## 성과 향상

데이터 기반 의사결정으로 가맹점 생존율 및 매출 안정성 제고

